




금융 AI 인프라스트럭처의 통제와 설계

모듈 2: 대규모 언어 모형(LLM)과 오픈소스 연구 도구

AI금융 세미나
(2026-Fall)

서강대학교
정재식 교수

도메인 전문가를 위한
AI 배관층(Plumbing Layer) 마스터 클래스

단순한 사용자를 넘어, 시스템의 설계자로

인프라의 이해 (The Plumbing)

AI를 마법이 아닌
'금융 인프라'로 이해합니다.
공개 모형(Open-source)과
상용 모형(Closed-source)
의 장단점을 파악하고
망분리 규제에 대응합니다.

도구의 통제 (The Switchboard & Vault)

OpenRouter(라우팅)와
Hugging Face(저장소)를
활용해 최적의 모델을
스왑하고 자산화하는
전략적 감각을 익힙니다.

연구의 적용 (Mimic & Reproduce)

바닥부터 코딩하는 대신,
NotebookLM과 RAG
아키텍처를 기존 문헌 연구에
적용하고 데이터(KOSPI 등)
를 교체하여 재현하는
실무 능력을 기릅니다.



평가 지침: 정규 시험 및 의무 Term Paper 없음.
최신 기술 탐색, 실전 토론, 비판적 검증 자체가 본 세미나의 핵심입니다.

금융 AI의 딜레마: 통제력인가, 편의성인가?


	상용 LLM (Astra, Fable, Gemini)	퍼블릭 Open-source (Llama, Mistral)	금융권 자체 구축 (Private SLM)
모델 성능 (SOTA)	최고 수준의 멀티모달 추론 및 코딩 보조. 보안 및 망분리 취약, 종속성 높음. (단계 1 단순 요약에 적합)	커뮤니티 기반의 빠른 발전. 여전히 클라우드 의존 시 데이터 외부 유출 리스크 존재.	오프라인 구동 필수. 데이터 완벽 통제 및 망분리 규제 100% 준수. 초기 인프라 구축 비용 발생. (장기 경제성 우수)
데이터 보안 (Data Privacy)	최고 수준의 멀티모달 추론 및 보안 및 망분리 취약 📡.	커뮤니티 기반의 빠른 발전. 데이터 외부 유출 리스크 존재.	데이터 완벽 통제 및 망분리 규제 100% 준수.
망분리 규제 준수 (Air-gapping)	보안 망분리 취약, 종속성 높음. 망분리 규제 준수	여전히 클라우드 의존 시 및 데이터 외부 유출 리스크 존재.	초기 인프라 구축 비용 발생. (장기 경제성 우수)
장기 운영 경제성 (Cost/Tokens)	보안 수준의 엄격한 상용 망분리 규제 준수	커뮤니티 기반의 빠른 발전. 여전히 외부 유출	초기 인프라 구축 비용 발생. (장기 경제성 우수)

한국 금융권의 엄격한 규제 환경에서 상용 API 의존은 보안 및 컴플라이언스의 한계에 직면합니다.
'자체 구축(Private SLM)' 역량은 선택이 아닌 필수 생존 전략입니다.


The Gateway: OpenRouter 통합 라우팅 전략

The Switchboard (OpenRouter)
- 단일 API 엔드포인트 통합 제어


경로 A (비용 최적화) → 단순 요약 작업



경로 B (성능 극대화) → 복잡한 수학 연산



경로 C (다중 모델 투표 - Multi-model Voting)



FOMC 회의록을
기반으로
금리 인상 확률을
분석하라

전략적 강점: 특정 AI 모델의 다운타임이나 요금 인상에 종속되지 않는
완벽한 '모델 스왑(Model Swap) 편의성'을 제공합니다.

라우팅 메커니즘의 실전 구현 (Minimal Viable Code)

```
import requests
```

```
# OpenRouter 단일 API를 통한 동적 모델 스왑 메커니즘
```

```
def fetch_financial_analysis(prompt, model_choice='anthropic/claude-3-fable'):
```

```
    response = requests.post(
```

```
        url='https://openrouter.ai/api/v1/chat/completions',
```

```
        headers={'Authorization': f'Bearer {OPENROUTER_API_KEY}'},
```

```
        json={
```

```
            'model': model_choice,
```

```
            'messages': [{'role': 'user', 'content': prompt}]
```

```
        }
```

```
    )
```

```
    return response.json()
```

단일 API 엔드포인트 유지
(코드 수정 최소화)

OpenAI, Google,
Anthropic 간
즉각적인 전환

구체적인 다중 모델 투표(Voting) 실습
및 프롬프트 엔지니어링은 배포된
'module_2_practice_v2.py'를
참조하여 Reproduce 하십시오.

The Vault: 'AI 생태계의 깃허브' Hugging Face

3,000,000+

호스팅 중인 AI 모델

모델 탐색 및 평가

금융 특화 사전 학습
모델(FinBERT 등) 검색.



5,000,000+

개방형 데이터셋

가중치 자산화

폐쇄형 API에 의존하지 않고
모델의 실질적인 '뇌(Weights)'를
직접 다운로드 및 소유.



18,000,000+


활성 개발자 및 연구자

투명성 확보

논문 기반의 경제학 연구 재현성
(Reproducibility)을 보장하는
데이터셋 및 모델 아카이브 역할.



금융 실무 활용: 망분리 환경과 Local Fallback 전략



비즈니스 가치: 외부 데이터 유출 제로(0%). 보안 감사를 통과하면서 AI 분석 역량을 사내 자산으로 영구히 내재화(Local Fallback).

[심화 분석] AI 배관층(Plumbing Layer)의 독점화

Deal 1: Nvidia의 Hugging Face 인수

**\$12.93
Billion**

AI 하드웨어 지배자가
최대 소프트웨어 모델
배포 허브까지
수직 계열화 달성.

Deal 2 : Stripe의 OpenRouter 인수

**\$7.50
Billion+**

글로벌 핀테크 거인이
AI 라우팅 게이트웨이를 및
자금 결제망(Pay-rails) 선점.

인사이트: 오픈소스로 시작된 AI 생태계의 핵심 인프라(저장소와 스위치)에
명확한 거대 자본의 주인이 생겼습니다.
무심코 사용하던 '퍼블릭 인프라'가 '프라이빗 톨게이트'로 변하고 있습니다.

전략적 함의 1: 하드웨어 중립성의 훼손 위험



Nvidia 리스크의 본질:

공식적으로는 '독립 플랫폼'을 유지한다고 선언했으나, 1,800만 명 규모의 스토리지와 대역폭을 유지하는 플랫폼이 Nvidia 산하에 들어감으로써, 결국 Nvidia Compute 생태계가 '가장 최적화된 표준 경로'로 고착화될 위험이 존재합니다.

포크(Fork)의 환상:

오픈소스 코드를 포크하여 대안을 만들 수 있다는 주장이 있으나, 수백만 개의 모델 가중치를 호스팅하는 막대한 자본력과 네트워크 효과를 자발적 진영이 단기간에 재현하는 것은 불가능에 가깝습니다 (완벽한 Lock-in).

CIO 액션 플랜: 특정 하드웨어 의존도를 낮추기 위한 '탈출 해치(Escape Hatch)' 아키텍처를 선제적으로 설계해야 합니다.

전략적 함의 2: 에이전트 이코노미(Agentic Economy) 결제망 선점



4. Stripe (Payment Rail)를 통해
토큰 단위 실시간 정산 완료

1. AI Agent A (리서치 봇)가
복잡한 수학 연산 필요


2. OpenRouter (Gateway)에
최적 효율의 모델 쿼리

3. AI Agent B (수학 특화 봇)로
동적 라우팅 및 작업 수행

단순한 비용 최적화를 넘어섭니다. 멀티 모델 에이전트가 알아서 최적의 모델로 토큰을 라우팅하고, 기계와 기계 간의 거래 대금을 실시간 정산하는 '자율 에이전트 금융망'의 상용화가 시작되었습니다. AI가 경제의 주체로 격상되는 변곡점입니다.

비즈니스 의사결정: 로컬 백업(Local Fallback)의 당위성

Renting API (Vulnerable)



초거대 테크 기업의 독점화로 인해 정책 변경, API 유료화, 혹은 다운타임 발생 시 기업의 AI 리서치 자산이 즉각적으로 마비될 위험.

Owning Infrastructure (Resilient)



핵심 금융 모델(FinBERT 등)의 가중치를 사내 물리적 온프레미스 서버에 영구적으로 백업하여 인프라 중립성 확보.

The Defensive Playbook: 단순 API 호출에만 의존하는 리서치를 탈피하고, 언제든지 다른 인프라로 전환할 수 있는 민첩성(Ecosystem Agnosticism)을 확보해야 합니다.

실전 문헌 연구 아키텍처: RAG & NotebookLM 파이프라인



1. **Question (질의)**
페르소나와 구조화된 프롬프트
(예: 공급망 리스크가
재무제표에 미칠 영향)


2. **Retrieval (검색)**
경제학 교과서, 최신 SEC
기업 공시(10-K), 산업 보고서
PDF 데이터베이스 쿼리

3. **Grounding (근거 결합)**
추출된 '진짜 텍스트'로만
컨텍스트 제한
(In-context Learning 강화)

4. **Generation (생성)**
환각(Hallucination)이
억제된 신뢰할 수 있는
금융 분석 초안 도출

핵심 가치: 외부의 거대한 파라미터가 아닌, '내가 소유한
신뢰할 수 있는 데이터'에 AI를 단단히 묶어두는 통제 기술.

비판적 검증: Human-in-the-Loop (인간 승인의 필수성)



실전 세미나 토론 I: 보안과 효용의 트레이드오프

Utility (효용성)



OpenAI Astra / Gemini 1.8 Flash.
방대한 컨텍스트와 압도적인 추론 속도로
과거 시장 데이터셋 전체를
지연 없이 분석하는 천재적 성능.

Security (보안성)



망분리 규제 완벽 준수.
외부 클라우드 접속을 원천 차단하는
자체 Private SLM 환경.
성능은 다소 떨어지나 리스크 제로.

토론 의제: 금융 기관의 리서치 헤드로서, Astra의 '천재적 분석력'을
포기하고 보안이 완벽한 자체 Private SLM을 선택하시겠습니까?
아니면 규제 당국을 설득해 클라우드 우회로를 찾으시겠습니까?

실전 세미나 토론 II: 인지적 위축(Cognitive Atrophy)의 리스크

현재의 기술:

AI와 NotebookLM이 수백 장의 실적 발표(Earnings Call)와 복잡한 거시경제 지표를 단 5초 만에 단 5초 만에 완벽하게 요약해 주는 시대.

토론 의제:

기초적인 데이터 수집과 텍스트 요약 과정의 고통(Struggle)을 건너뛴 주니어 애널리스트는, 시장의 미묘한 뉘앙스를 포착하는 '직관(Intuition)'과 '감(Gut feeling)'을 어떻게 기를 수 있을까요?

완벽하게 요약된 정답만 소비하는 환경에서, 미래의 위대한 투자자는 어떻게 탄생할 것인가?

AI는 도구일 뿐, 금융의 본질은 리스크를 짚어지는 인간의 결단에 있습니다.

